

UNIVERSIDADE PRESBITERIANA MACKENZIE

Curso de Ciência de Dados

PROJETO APLICADO II – ETAPA 1

Projeto de Ciência de Dados com Manipulação de Texto

Aluno: Enzo Enrico Braga Cavalcante
RA: 10744145
Local: Guarulhos – 2026

Este documento apresenta a proposta inicial do Projeto Aplicado II. O objetivo desta etapa é definir o grupo de trabalho, estabelecer as premissas do projeto (organização escolhida, área de atuação e dados utilizados), além de apresentar os objetivos, metas e o cronograma inicial das atividades do projeto.

1. Grupo de Trabalho

O projeto será desenvolvido pelo seguinte integrante:

- Enzo Enrico Braga Cavalcante – Responsável pela análise de dados, desenvolvimento do modelo e documentação do projeto.

O trabalho seguirá uma organização baseada em boas práticas de projetos de ciência de dados, incluindo versionamento de código, documentação técnica e estruturação reprodutível do pipeline de dados.

2. Premissas do Projeto

2.1 Organização escolhida

A organização escolhida para o projeto é a Netflix, empresa global de entretenimento digital especializada em streaming de filmes e séries. A empresa utiliza análise de dados em larga escala para compreender preferências de usuários, melhorar recomendações e avaliar a recepção de conteúdos.

2.2 Área de atuação

A área analisada neste projeto será a análise de opinião de usuários (Sentiment Analysis) aplicada a avaliações e comentários de filmes e séries. Essa área é amplamente utilizada por plataformas de streaming para compreender a percepção do público sobre conteúdos disponibilizados na plataforma.

2.3 Apresentação dos dados (Texto)

O projeto utilizará um conjunto de dados composto por avaliações textuais de usuários sobre filmes e séries. Esses dados contêm comentários escritos pelos usuários e classificações associadas (positivas ou negativas). O objetivo será aplicar técnicas de processamento de linguagem natural (NLP) para identificar automaticamente o sentimento presente nos textos.

Exemplos de variáveis (metadados) presentes no dataset:

- review_text – texto da avaliação escrita pelo usuário.
- sentiment – classificação do sentimento (positivo ou negativo).
- review_length – tamanho do comentário em número de palavras.
- movie_title – título do filme ou série avaliada.

Esses dados permitem a aplicação de técnicas de limpeza textual, vetorização (TF-IDF ou embeddings) e modelos de aprendizado de máquina para classificação de sentimento.

3. Objetivos e Metas

O objetivo geral do projeto é desenvolver um modelo de ciência de dados capaz de classificar automaticamente o sentimento de avaliações de usuários sobre conteúdos de streaming.

Objetivos específicos:

- Realizar aquisição e preparação dos dados textuais.
- Aplicar técnicas de pré-processamento de texto (remoção de stopwords, tokenização e normalização).
- Implementar modelos de classificação de texto utilizando aprendizado de máquina.
- Avaliar o desempenho dos modelos utilizando métricas como acurácia, precisão e recall.
- Documentar todo o processo analítico em repositório versionado.

Metas do projeto:

- Construir um pipeline completo de análise de dados textuais.
- Desenvolver um modelo com desempenho satisfatório para classificação de sentimento.
- Garantir reprodutibilidade do projeto por meio de código e documentação.

4. Cronograma de Atividades (Estimativa)

Etapa	Descrição	Período Estimado
1	Definição do problema e escolha do dataset	Semana 1
2	Aquisição e preparação dos dados	Semana 2
3	Análise exploratória dos dados	Semana 3
4	Pré-processamento de texto (NLP)	Semana 4
5	Treinamento de modelos de machine learning	Semana 5
6	Avaliação de modelos e ajustes	Semana 6
7	Documentação e organização do repositório	Semana 7
8	Elaboração do relatório final e apresentação	Semana 8

5. Repositório do Projeto

O código-fonte, dataset tratado e notebooks utilizados no projeto estarão disponíveis no seguinte repositório GitHub:

Link do repositório:

<https://github.com/Enzo-Enrico/Projeto-Aplicado-II-Analise-Sentimento>