

UNIVERSIDADE PRESBITERIANA MACKENZIE

Curso de Ciência de Dados

PROJETO APLICADO II – ETAPA 2

Aluno: Enzo Enrico Braga Cavalcante
RA: 10744145
Local: Guarulhos – 2026

1. Definição da linguagem de programação

A linguagem escolhida para o desenvolvimento do projeto é Python, devido à sua ampla utilização em Ciência de Dados e Machine Learning. A linguagem oferece bibliotecas como Pandas, NumPy, Scikit-learn, NLTK e Matplotlib, permitindo desde a manipulação dos dados até a modelagem e avaliação dos modelos.

2. Análise exploratória da base de dados

A análise exploratória tem como objetivo compreender as características do dataset de avaliações textuais. Serão analisadas a distribuição dos sentimentos, o tamanho dos textos, frequência de palavras e possíveis desbalanceamentos, utilizando bibliotecas como Pandas e Matplotlib.

3. Tratamento da base de dados

O tratamento dos dados inclui pré-processamento de texto (remoção de stopwords, tokenização e normalização), transformação em vetores numéricos utilizando TF-IDF e divisão do dataset em treino (80%) e teste (20%). Serão utilizados modelos como Naive Bayes, Regressão Logística e SVM.

4. Bases teóricas dos métodos

O projeto utiliza conceitos de Processamento de Linguagem Natural (NLP), TF-IDF e algoritmos de classificação. Essas técnicas permitem transformar texto em dados estruturados e aplicar modelos preditivos.

5. Avaliação e cálculo da acurácia

A acurácia será calculada como a razão entre previsões corretas e o total de previsões. Também serão utilizadas métricas como precisão, recall e F1-score, além da matriz de confusão para avaliação detalhada.